ЛАБОРАТОРНАЯ РАБОТА 2
ОБРАБОТКА ПОТОКОВЫХ ДАННЫХ

Задачи:

- Изучить различия между пакетной и потоковой обработкой данных;
- Настроить инфраструктуру для потоковой обработки (Kafka, Spark/Flink);
- Реализовать потоковую обработку входящих сообщений с учетом времени события и времени обработки;
- Применить оконные функции: фиксированные (tumbling), скользящие (sliding), сеансовые (session);
- Научиться управлять состоянием потока (stateful stream processing).
- Измерить задержки (latency), throughput и сравнить подходы в разных инструментах.

Шаги:

1. Развернуть локальный кластер Kafka (Zookeeper + Broker).
2. Написать продюсера на Python для имитации потока событий (JSON-сообщения с timestamp).
3. Реализовать стрим-приложение на:
   а. Spark Structured Streaming
   б. Flink DataStream API
4. Для каждого приложения:
   а. Обработать события с учётом event-time (с водяными метками).
   б. Применить tumbling, sliding и session-windows.
   в. Поддерживать состояние: подсчет количества событий по ключу за минуту.
   г. Замерами показать задержку end-to-end и пропускную способность.